

잔차 동역학 학습 기반 공압 인공근육 휴머노이드 핸드의 강화학습 파지 및 조작 제어

Abstract

본 연구는 공압 인공근육(PAM) 구동 휴머노이드 핸드의 강화학습 제어를 위해 Chou-Hannaford 분석 모델과 잔차 동역학 신경망(RDN)을 결합한 프레임워크 및 Sim-to-Sim Gap 검증 프로토콜을 제안한다. 시뮬레이션 실험 결과, 대표 antagonistic 관절 쌍 기준 Sim-to-Sim Gap을 분석 모델 단독 대비 88.8% 감소시켰고, 동일 RDN을 모든 관절 쌍에 공유 적용한 환경에서 Multi-Object Grasping 84%→96%, In-hand Cube Rotation 56%→74%를 달성하였다. 정량 검증은 시뮬레이션 환경 내에서 수행되며, 실제 하드웨어 평가는 본 논문 범위에 포함되지 않는다.

I. 서론

공압 인공근육(Pneumatic Artificial Muscle, PAM)은 높은 출력 대 무게비와 본질적 컴플라이언스로 휴머노이드 핸드의 구동기로 주목받고 있으나, 비선형 압력-수축 관계, 히스테리시스, 응답 지연으로 인해 모델 기반 제어로는 정밀 조작이 어렵다. 이에 강화학습이 활용되고 있으나, 실제 PAM 핸드에서의 학습은 하드웨어 손상 위험과 시간 비용으로 제한적이며, Isaac Sim과 같은 고충실도 시뮬레이션이 일반적이다.

그러나 표준 시뮬레이터는 강체 모터 가정에 기반하여 PAM 특유의 비선형 동역학을 충분히 재현하지 못하며, 단순한 물리 파라미터 보정만으로는 모델 부정합을 해소하기 어렵다. 이를 해결하기 위해 본 연구는 (i) PAM 분석 모델로 포착되지 않는 비선형 잔차를 학습하는 Residual Dynamics Network(RDN)와 (ii) 학습/평가 환경 분리를 통한 Sim-to-Sim Gap 평가 프로토콜을 제안한다.

II. 관련 연구

PAM의 동역학 모델링은 Chou and Hannaford [1]가 제안한 정역학 기반 힘 모델 이래로 활발히

연구되어 왔으며, Tondou [2] 등이 마찰과 컴플라이언스를 포함한 확장 모델을 제시하였다. 한편, 다지 핸드의 강화학습 제어 측면에서는 SAC(Soft Actor-Critic) [3]와 같은 연속 제어 알고리즘이 표준으로 자리 잡았으며, Isaac Gym [4]과 같은 GPU 기반 시뮬레이션 환경은 대규모 병렬 학습을 가능하게 하여 In-hand manipulation 연구를 가능하게 하였다.

Sim-to-Real Gap 완화를 위한 접근으로 Domain Randomization과 System Identification이 활용되어 왔으나, 이들은 주로 강체 동역학 환경을 가정하며 PAM과 같은 비선형 컴플라이언스 구동기에는 한계가 있다. 최근 Hwangbo et al. [5]과 Golemo et al. [6]은 분석 모델만으로 포착되지 않는 잔차 동역학을 신경망으로 학습하는 Residual Dynamics Learning을 제안하여 사족 보행 및 단순 매니퓰레이터에서 효과를 보였으나, 다지 PAM 핸드에 대한 적용 사례는 보고된 바가 매우 적다. 본 연구는 PAM 분석 모델과 RDN의 결합 및 Sim-to-Sim Gap 평가 프로토콜을 통해 이러한 격차를 해소한다.

III. 제안 방법



그림 1. PAM 구동 휴머노이드 핸드(실물 테스트베드)

본 연구의 모델링 대상이 되는 5지 PAM 구동 휴머노이드 핸드 테스트베드. 정량 평가는 시뮬레이션 환경에서 수행되었으며, 실물 테스트베드는 향후 Sim-to-Real 검증을 위한 참조용이다.

3.1 PAM 분석 모델 통합

다지 핸드의 기구학적 구조를 URDF 형식으로 모델링한 후, 각 관절 구동기를 PAM으로 대체하기 위해 Chou-Hannaford 정역학 모델을 시뮬레이터에

통합한다. PAM이 발생시키는 수축력은 내부 압력과 수축물의 함수로 다음과 같이 표현된다.

$$F(P, \varepsilon) = (\pi D_0^2 P / 4) \cdot [a(1 - \varepsilon)^2 - b] \quad \dots \text{식}(1)$$




그림 2. Chou-Hannaford 모델 기반 PAM 정역학

그림 2는 식(1)의 정역학을 1~6 bar에서 시각화한 결과로, ε 이 0.05→0.20일 때 발생력이 약 30% 감소(antagonistic 관절의 작동점 의존 강성)하고 압력 곡선이 부채꼴로 펼쳐져(단순 스케일링 불가능한 결합 효과) 강체 모터 가정을 벗어남을 보인다. 식(1)에서 P는 내부 압력, ε 는 수축률, D_0 는 초기 직경, a, b는 직조 각도 관련 무차원 파라미터이며, Chou-Hannaford [1] 표준 McKibben PAM(직조 각도 약 23°) 대표값 $a=3.0$, $b=1.0$ 을 시뮬레이션 명목값으로 사용하였다. 압력 P는 동적이므로 공압 회로 응답을 1차 지연 시스템으로 모델링한다(식(2)).

$$\tau \cdot dP/dt + P = K \cdot u(t) \quad \dots \text{식}(2)$$

여기서 τ 는 시정수, K는 정상상태 이득, $u(t)$ 는 제어 입력이다. PAM 쌍의 길이 변화로부터 관절 토크를 계산하여 시뮬레이션의 관절 구동력으로 입력한다.

3.2 잔차 동역학 학습 (Residual Dynamics Network)

분석 모델 (1)~(2)는 PAM의 거시적 거동을 잘 설명하지만, 직조 마찰의 비선형 손실, 점탄성 변형, 공압 회로의 비대칭 응답 등 모든 현상을 포착하지는 못한다. 이러한 잔차 동역학을 보정하기 위해 본 연구에서는 Residual Dynamics Network(RDN)를 도입한다. RDN은 현재 상태 s_t 와 행동 a_t 를 입력으로 받아 분석 모델 예측 상태와 고충실도 기준 상태 간의 차이를 출력하는 다층 신경망 g_φ 로 구성된다.




그림 3. 동일 압력 입력에 대한 분석 모델(파랑)과 풀 모델(녹색)의 응답 차이

그림 3은 동일 사인과 압력 입력 하 두 모델의 응답 차이를 보여준다. 거시적 궤적은 유사하나 다음의 체계적 차이가 일관되게 나타난다. 첫째, 상승 구간과 하강 구간의 비대칭성-충전(0.05 s)/배출(0.09 s) 시정수 비대칭으로 풀모델 하강이 더 느려 대칭 가정 분석 모델과 격차가 발생한다. 둘째, 마찰 손실-큰 수축 변위에서 풀모델 발생력이 작아져 관절각에 작은 정상상태 오차가 생긴다. 이 잔차는 직조 마찰·점탄성·비대칭 응답이 결합한 결과로, 분석 모델 식(1)~(2)의 폐형 표현으로는 명시적으로 모델링되지 않는다. 본 연구는 이 잔차를 데이터 기반으로 학습하는 RDN을 다음 절에서 제안한다.

$$s_{t+1} = f_{ana}(s_t, a_t) + g_\varphi(s_t, a_t) \quad \dots \text{식}(3)$$

$$L(\varphi) = E[\|s_{ref}\{t+1\} - (f_{ana}(s_t, a_t) + g_\varphi(s_t, a_t))\|^2] \quad \dots \text{식}(4)$$

여기서 f_{ana} 는 식(1)~(2) 분석 모델, g_φ 는 학습 가능한 RDN, $\hat{s}_{ref}\{t+1\}$ 은 마찰·점성·비대칭 응답을 포함한 풀모델 기준 환경의 다음 상태이다. RDN은 사전 수집한 $(s_t, a_t, \hat{s}_{ref}\{t+1\})$ 삼중쌍으로 식(4)를 최소화하도록 오프라인 학습되어 RL 환경에 동결 통합되며, 잔차 가산은 압력·관절각 단위 차이로 인한 불균형을 막기 위해 정규화 공간에서 수행 후 역정규화된다. RDN은 대표 antagonistic 관절 쌍 단위(입력 6, 출력 4차원)로 학습하고 다지 핸드 전체에는 동일 가중치 g_φ 를 모든 관절 쌍에 공유(weight-shared) 적용하며, 이는 모든 손가락이 동일 PAM·공압 회로 특성을 공유한다는 가정에 기반한다.

3.3 강화학습 정책 학습

RDN으로 보정된 학습 환경 위에서 연속 제어에

적합한 SAC(Soft Actor-Critic) 알고리즘으로 파지 및 조작 정책을 학습한다. 상태는 각 PAM의 압력 및 수축률, 손가락 관절 각도 및 각속도, 물체의 위치·자세·선속도로 구성되며, 행동은 각 PAM에 인가되는 정규화된 압력 명령으로 설정된다. 보상 함수는 물체와 손끝의 접촉 안정성, 목표 자세까지의 거리, 그리고 PAM 압력 변화의 부드러움을 종합적으로 반영한다. 학습은 Isaac Gym 기반 병렬 환경(4096 env)에서 수행한다. 재현성을 위한 주요 하이퍼파라미터는 다음과 같다. [SAC: $\text{lr} \times 10^{-4}$, batch 4096, replay 10^6 , $\gamma=0.99$, $\tau=0.005$, hidden (256,256), 총 2×10^7 step, 5 seeds]

IV. 실험

제안 방법의 성능을 검증하기 위해 Isaac Gym 기반 병렬 시뮬레이션 환경에서 두 가지 실험을 수행하였다.

4.1 실험 환경 파라미터

표 1은 실험 파라미터를 요약한다. PAM은 직경 10 mm 표준 McKibben [1, 2] 기준이며 충전/배출 시정수를 비대칭(0.05/0.09 s)으로 설정해 공압 응답 비대칭을 반영하였다. 정량 검증은 대표 antagonistic 관절 쌍 1개에서 수행하며, RDN은 입력 6차원($s_t = [q, \dot{q}, P_{ag}, P_{ant}] + a_t = [u_{ag}, u_{ant}]$), 출력 4차원 잔차 $\Delta s_{(t+1)}$ 로 구성된 $6 \rightarrow 64 \rightarrow 64 \rightarrow 4$ MLP를 폴모델 20,000 천이 샘플로 학습하였다.

범주	파라미터	값
PAM 분석 모델 (Chou-Hannaford)	초기 직경 D_0	10 mm
	직조 기하 파라미터 a, b	3.0, 1.0
	시정수 τ	0.05 s
	최대 압력 P_{max}	6 bar
PAM 폴모델 (추가 비선형 행)	직조 마찰 계수 μ	0.15
	점성 계수 c_v	0.08
	충전/배출 시정수 비대칭	0.05 / 0.09 s
Antagonistic 관절	관성 J	$1.0 \times 10^{-3} \text{ kg}\cdot\text{m}^2$
	폴리 반경 r	15 mm
	관절 한계	$\pm\pi/3 \text{ rad}$
Residual Dynamics Network	구조 (MLP)	$6 \rightarrow 64 \rightarrow 64 \rightarrow 4$
	활성화 함수	ReLU
	옵티마이저	Adam ($\eta = 10^{-3}$)
	학습 데이터 / 에포크	20,000 / 200
시뮬레이션 & 평가	적분 시간 간격 Δt	10 ms
	평가 trial 수	30
	Sim2Sim 평가 정책	PD ($k_p=2.0, k_d=0.1$)

표 1. 실험 환경 파라미터 설정

표 1의 파라미터 중 폴모델 환경의 직조 마찰 계수($\mu = 0.15$), 점성 계수($c_v = 0.08$), 비대칭 시정수 차이는 분석 모델 (식(1)~(2))에서 명시적으로 모델링 되지 않은 항들로, 본 연구의 잔차 동역학에 해당한다. 즉, RDN이 학습해야 할 대상은 이러한 파라미터들이 유발하는 동역학적 차이이다. 분석 모델과 폴모델

사이의 의도적 부정합은 실제 PAM 핸드와 표준 시뮬레이터 간의 Sim-to-Real Gap을 시뮬레이션 환경 안에서 모사하기 위한 설계 선택이며, 이 부정합의 크기는 표 1의 파라미터 조정으로 통제할 수 있다. 다만 본 절차는 실제 하드웨어 검증을 대체하는 것이 아니라 시뮬레이션 내부에서의 동역학 강건성 평가에 한정되며, 실측 PAM과의 직접적 Sim-to-Real 전이 검증은 본 논문의 범위에 포함되지 않는다.

4.2 실험 시나리오

두 실험은 다양한 물체에 대한 Multi-Object Grasping(파지력 안정성)과 다섯 손가락 협조 정육면체 회전 In-hand Cube Rotation(응답 지연 정밀 조작)이다. 지표는 파지 성공률, 회전각 도달률, 학습/평가 환경 관절 제적 RMSE 기반 Sim-to-Sim Gap이며, 성공률은 5 seeds $\times$ 50 episodes(총 250) 평균이다. 성공 판정: Grasping은 5초 내 손끝 접촉력 양수·물체 +5 cm 상승·마지막 1초 표준편차 $\leq 3 \text{ mm}$, Rotation은 8초 내 오차 $\leq 0.2 \text{ rad}$ 가 1초 이상 유지. Sim-to-Sim Gap은 PD($k_p=2.0, k_d=0.1$) 사전 생성 압력을 두 환경에 open-loop 인가, 무작위 사인과 30회 평균±표준편차를 보고한다.

V. 실험 결과

Multi-Object Grasping에서 강체 모터 베이스라인은 PAM 폴모델 평가 환경에서 약 62%로 급락하여 PAM 컴플라이언스-강체 가정 격차를 드러냈고, PAM 분석 모델 단독은 84%, 제안 분석+RDN은 96%로 가장 높은 성공률을 기록한다. RDN 학습은 그림 4와 같이 초기 30 에포크 내에 손실이 한 자릿수 가까이 감소하며 안정적으로 수렴하여 200 에포크에서 정규화된 MSE 약 3.7×10^{-2} 에 도달하였다.




그림 4. RDN 학습 손실 곡선

병렬 학습 실험에서는 RDN 추가 비용에도 학습 처리량이 환경 수에 비례하여 확장되었다. 이는 RDN이 GPU 상에서 배치 단위로 평가되어 강화학습 루프 상의 주요 병목으로 작용하지 않음을 시사한다.

In-hand Cube Rotation 실험에서는 목표 회전각에 대한 도달률이 PAM 분석 모델 단독은 응답 지연 미보정으로 56%에 그쳤으나, 제안 방법은 74% (+18%p)를 달성하였다.




그림 5. Sim-to-Sim Gap 막대그래프

그림 5와 같이 학습 환경과 평가 환경 간 관절 궤적 RMSE를 측정한 결과, 강체 모터 베이스라인은 0.560 ± 0.259 rad의 큰 Sim-to-Sim Gap을 보였으나, PAM 분석 모델 단독은 0.170 ± 0.061 rad, 제안 방법은 0.019 ± 0.031 rad로 약 88.8%의 추가 감소($(0.170 - 0.019) / 0.170 = 0.888$)를 달성하였다.




그림 6. 환경별 관절 궤적 및 절대 오차

그림 6에서 제안 방법(빨강)은 풀모델 참조(녹색)와 거의 일치하며, 분석 모델 단독(파랑)은 천이 구간 최대 0.5 rad, 강체 베이스라인(회색)은 구간 최대 약 1.5 rad의 추종 오차를 보인다. 하단 절대 오차 패널은 RDN이 천이 구간에서도 잔차를 효과적으로 추적함을 시사한다. 이는 본 연구의 Sim-to-Sim Gap 평가 프로토콜이 동역학 부정합 보정 효과를 정량적으로 검증할 수 있음을 보여준다.

VI. 결론

본 연구는 PAM 구동 휴머노이드 핸드를 위해 Chou-Hannaford 분석 모델과 RDN을 결합한 프레임 워크 및 Sim-to-Sim Gap 평가 프로토콜을 제안하였다. 제안 방법은 대표 antagonistic 관절 쌍에서 Sim-to-Sim Gap을 분석 모델 단독 대비 88.8% 감소시켰고, Multi-Object Grasping에서 84%→96%를 달성하였다. In-hand Cube Rotation은 56%→74% (+18%p)로 개선되었으나 강체 베이스라인(80%)에는 미치지 못한 점이 한계로 남았다.

Sim-to-Sim Gap 정량 검증은 관절 쌍 단위에서 수행하였다. 관절 별 개별 동역학 차이와 다자유도 결합 검증은 향후 연구로 남긴다.

참고문헌

- [1] C.-P. Chou and B. Hannaford, "Measurement and modeling of McKibben pneumatic artificial muscles," IEEE Trans. Robotics and Automation, vol. 12, no. 1, pp. 90–102, 1996.
- [2] B. Tondu, "Modelling of the McKibben artificial muscle: A review," J. Intelligent Material Systems and Structures, vol. 23, no. 3, pp. 225–253, 2012.
- [3] T. Haarnoja et al., "Soft Actor-Critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor," in Proc. ICML, 2018, pp. 1861–1870.
- [4] V. Makoviychuk et al., "Isaac Gym: High performance GPU-based physics simulation for robot learning," in Proc. NeurIPS Datasets and Benchmarks, 2021.
- [5] J. Hwangbo et al., "Learning agile and dynamic motor skills for legged robots," Science Robotics, vol. 4, no. 26, eaau5872, 2019.
- [6] F. Golemo et al., "Sim-to-real transfer with neural-augmented robot simulation," in Proc. CoRL, 2018, pp. 817–828.